

Anwendungen

Thorsten Lüttel*, Felix Ebert, Dennis Faßbender, Carsten Fries, Benjamin C. Heinrich, Hanno Jaspers, Jan Kallwies, Benjamin Naujoks und Hans-Joachim Wünsche

Assistenz- und Autonomiefunktionen zur Entlastung des Fahrers in Offroad-Szenarien

Autonomous driving functions reducing the driver's cognitive load in off-road scenarios

<https://doi.org/10.1515/auto-2017-0013>

Eingang 16. Februar 2017; angenommen 8. Juni 2017

Zusammenfassung: Im Onroad-Bereich sind viele Fahrerassistenzsysteme bereits serienreif oder stehen kurz davor. Ändert sich die Umgebung hin zu Offroad, so sind aufgrund anderer Nutzeranforderungen und vor allem aufgrund der Umgebungseigenschaften in vielen Fällen andere Assistenz- und Autonomiefunktionalitäten gefordert. In diesem Artikel stellen wir vom Institut für Technik Autonomer Systeme (TAS) entwickelte Funktionalitäten vor, die den Fahrer in Offroad-Szenarien entlasten können. Zum einen handelt es sich hier um einen Konvoi-Assistenten, der das spurgetreue Folgen hinter einem anderen Fahrzeug ermöglicht, zum anderen um einen Mule-Assistenten für den Lastentransport zwischen zwei Lagern. Anhand von zwei Wettbewerbsszenarien aus der M-ELROB 2016 werden diese Funktionalitäten evaluiert.

Schlüsselwörter: Autonomes Fahren, Fahrerassistenz, Objekttracking, Navigation, Offroad.

Abstract: For use in on-road scenarios, many driver assistance systems have reached series-production readiness or are close to doing so. But if the environment changes to off-road, the users' requirements and especially the environment's parameters demand other assistance and autonomy functions. In this article we present some functionalities developed by our institute which can decrease the driver's cognitive load in those off-road scenarios: The convoy assist enables precise following of other vehicles in

nearly all environments, and the mule assist helps move load between two camps. The scenarios of the M-ELROB 2016 robotics competition are used for evaluation.

Keywords: Autonomous driving, advanced driver assistance systems, object tracking, navigation, off-road.

1 Einleitung

Assistenz- und Autonomiefunktionen für Kraftfahrzeuge haben sich in den letzten Jahren und Jahrzehnten rasant weiterentwickelt, sowohl auf der Straße als auch abseits davon.

In den 1980er Jahren wurden die Grundlagen für die Autonomiefunktionen gelegt: In den USA fuhr die Carnegie Mellon University mit den Navlab-Fahrzeugen [1] in strukturierter Umgebung, in Europa war die UniBw München auf der Autobahn mit höherer Geschwindigkeit [2] autonom unterwegs. Im öffentlich geförderten EUREKA-PROMETHEUS-Projekt arbeiteten einige europäische Universitäten und Industriefirmen an der Weiterentwicklung des autonomen Fahrens. In der Abschlussdemonstration 1994 navigierten die Fahrzeuge von Daimler Benz und der UniBw München vollautonom auf der mehrspurigen französischen Ringautobahn. Für gewisse Manöver wie Spurwechsel war allerdings ein Sicherheitsfahrer mit an Bord [3].

Für den militärischen Bereich in den USA wurde im *National Defense Authorization Act for Fiscal Year 2001* [4] die Forderung erhoben, dass bis zum Jahr 2015 ein Drittel der Landfahrzeuge unbemannt sein sollten. Die Defense Advanced Research Projects Agency (DARPA) verlieh daraufhin durch die Organisation von drei Wettbewerben der Entwicklung im autonomen Fahren – sowohl zivil als auch militärisch – einen großen Schub. In den Grand Challenges 2004 und 2005 [5] musste eine Route durch die Wüste absolviert werden, hier siegte 2005 das Stanford Racing

*Korrespondenzautor: Thorsten Lüttel, Institut für Technik Autonomer Systeme, Universität der Bundeswehr München, Neubiberg, E-Mail: thorsten.luettel@unibw.de

Felix Ebert, Dennis Faßbender, Carsten Fries, Benjamin C. Heinrich, Hanno Jaspers, Jan Kallwies, Benjamin Naujoks, Hans-Joachim Wünsche: Institut für Technik Autonomer Systeme, Universität der Bundeswehr München, Neubiberg

Team [6] mit dem Fahrzeug Stanley. Die Urban Challenge 2007 [7] fand auf einem vorstadtähnlichen Parcours statt, auf dem sich alle Teams gleichzeitig, zusammen mit manuell gesteuerten Fahrzeugen, bewegten. Sieger war hier das Team Tartan Racing der Carnegie Mellon University mit dem Fahrzeug BOSS [8]. In allen DARPA-Wettbewerben war eine durch tausende Wegpunkte beschriebene Straßenkarte verfügbar. Der Schwerpunkt lag zunächst auf Lokalisierung – primär mittels Globaler Satellitennavigationssysteme (GNSS) wie dem US-amerikanischen Navstar GPS oder dem russischen GLONASS – und Hindernisvermeidung, später dann auf Planung und Verhalten.

Assistenzsysteme im Onroad-Bereich. Aus diesen frühen Entwicklungen sind viele Teilfunktionalitäten entstanden, die heute als Fahrerassistenzsystem (FAS) in Serien-PKWs und -LKWs verfügbar sind: Die Spurerkennung wird sowohl für passive FAS in Form eines „Spurverlassenswarners“ als auch für den aktiven Spurhalteassistenten verwendet, funktioniert allerdings nur auf befestigter, markierter Straße. Erkennung und Tracking von dynamischen Objekten ist Grundvoraussetzung für u. a. Abstandsassistenten (ACC), Totwinkelassistenten und Notbremsassistenten. Letzterer greift bei unausweichlichem Zusammenstoß zur Reduktion der Unfallsschwere ein. In bisherigen FAS sind oftmals Zulieferer für einzelne Funktionen zuständig, die nicht miteinander interagieren. Dabei greift jede Funktion auf eigene Sensoren und Steuergeräte zurück. Derzeit geht der Trend zu stärkerer Integration in ein „zentrales FAS“ [9], in dem mehrere Funktionen die gleichen Sensordaten nutzen.

In den letzten Jahren wurde auch die Kopplung mehrerer Assistenten serienreif, die zugleich in Längs- und Querverführung unterstützen. Allerdings handelt es sich weiterhin um eine Teilautomatisierung unter der Aufsicht des Fahrers, da dieser aus rechtlichen Gründen weiterhin dauerhaft als Überwachungsinstanz agiert. Tesla bewirbt sein System offensiv als „Autopilot“ – anfangs ohne Überprüfung, ob der Fahrer seiner Kontrollfunktion nachkommt, was zu Missbrauch und tödlichen Unfällen führte [10]. Die traditionellen Fahrzeughersteller sind sowohl in der Fahrerüberwachung als auch in der Werbung konservativer, Mercedes Benz bezeichnet sein System als „Drive Pilot“ („Abstands-Pilot“ plus aktive Spurwechselassistenten).

Der Übergang von Fahrerassistenz zu Autonomie im Straßenverkehr ist derzeit also fließend, es gibt weiterhin vielfältige universitäre wie industrielle Aktivitäten. Nahezu alle Automobilhersteller und auch viele Zulieferbetriebe unterhalten in den USA Forschungszentren, da dort in einigen Bundesstaaten etwas einfachere Möglichkeiten

zur Erprobung autonomen Fahrens im Straßenverkehr als hierzulande gegeben sind.

Ein starker Trend ist die Verwendung präziser Karten zur Lokalisierung, z. B. im Google Self Driving Car [11] oder dem Demonstrator Bertha von Mercedes Benz und dem Karlsruher Institut für Technologie (KIT) [12]. Vor diesem Hintergrund hat 2015 ein Konsortium aus deutschen Automobilherstellern den Kartenspezialisten HERE übernommen. Die Abhängigkeit von solch präzisen Karten schränkt jedoch das Einsatzgebiet auf größere, viel befahrene Straßen ein, es wird sich kommerziell nicht lohnen jeden Feldweg zu kartieren und zyklisch zu aktualisieren.

Im öffentlichen Personennahverkehr wird derzeit intensiv an der Automatisierung geforscht. Zu nennen sind sowohl fahrerlose Busse, an denen zum Beispiel Navya Technology oder Local Motors arbeiten und die teilweise bereits im Probetrieb sind, als auch automatisierte Taxis, wie sie von Lyft oder Uber entwickelt werden. Auch für den Transport von Waren zwischen mehreren Lagern ist es oft sinnvoll, unbemannte Fahrzeuge zu verwenden. In Industriehallen werden solche fahrerlosen Transportsysteme (AGV, Automated Guided Vehicle) heute schon vielfach verwendet, auch in der Hoflogistik oder der Hafenautomatisierung kommen AGV meist zur Kostenreduktion im Personalbereich zum Einsatz [13].

Assistenzsysteme im Offroad-Bereich. Verlässt man die befestigte Straße, so ändern sich aufgrund von Erschütterungen und Schmutz zunächst die Anforderungen an die verwendete Hardware. Obwohl die Anforderungen an die Robustheit des Fahrzeugs bereits im manuellen Betrieb erhöht sind, steigen sie für autonome Fahrzeuge weiter, da im Notfall kein Mensch mehr vor Ort ist, um kleine Schäden zu beseitigen.

Vor allem die Sensoren reagieren auf Verschmutzung sehr empfindlich, zum Beispiel auf Staub vor der Kameralinse oder Schneematsch an Sensoren in der Frontschürze. Eine Sensorreinigung findet auch bei Serienstraßenfahrzeugen bereits statt, so sind viele Kameras hinter der Windschutzscheibe im Bereich des Scheibenwischers montiert. Offroad ist diese fast unabdingbar, seien es Scheibenwischer für im Innenraum integrierte Kameras oder Druckluft- bzw. Wasserstrahlreinigung für externe Kameras oder LiDAR-Sensoren (Light Detection And Ranging). Auch die Gefährdung durch Steinschlag oder Vegetation ist nicht zu vernachlässigen, hier hilft im Zweifel Redundanz im Sensorkonzept.

Herausfordernde Szenarien abseits der befestigten Straße bot die oben vorgestellte DARPA Grand Challenge, hier kam es zum Ausfall diverser Roboter. Des Weiteren ist die VisLab Intercontinental Autonomous Challenge [14, 15]

zu nennen, bei der vier gleichartige Fahrzeuge im Konvoi mehr oder weniger autonom von Parma/Italien zur Expo 2010 nach Shanghai/China fahren.

Zusammenfassend gibt es zwei Hauptanwendungsbereiche für FAS und Autonomiefunktionen im Offroad-Bereich: die Landwirtschaft sowie Militär- und Katastrophenschutzkräfte.

In der Landwirtschaft sind selbstfahrende Arbeitsmaschinen wie Traktoren oder Mähdrescher schon seit einigen Jahren in Serie. Hier gibt es aufgrund des nichtöffentlichen Geländes weniger rechtliche Bedenken, und im Gegensatz zur Straße sind die Szenarien wesentlich strukturierter. Als Systemanbieter sind hier unter anderem John Deere [16] und Claas [17] zu nennen. Ein Sicherheitsfahrer ist oft weiterhin an Bord, hat durch die Entlastung von der Fahraufgabe jedoch mehr Zeit für erntebezogene Aufgaben. Die Überlappungsminimierung bei der Bearbeitung von Feldern erfordert sehr präzise Spurführung, welche sich durch RTK-GNSS-basierte Lokalisierung oder durch eine sensorbasierte Orientierung an der letzten Bearbeitungskante erreichen lässt. So wird neben der Bearbeitungsdauer und den Kosten auch die Beanspruchung des Bodens gesenkt. Im Zuge des *Precision Farming* unterstützen weitere Assistenzsysteme [18] die Optimierung der auszubringenden Düngermenge durch die Verwendung präziser Bodenkarten und sensorbasierter Wuchsanalyse. Dadurch resultieren sowohl Kostenreduktion als auch Ressourcenschonung. Weitere Ansätze verfolgen beispielsweise das Bearbeiten im Team, in dem ein Bediener zwei oder mehr Traktoren bewegt. Pflanz- und Ernteroboter [19] werden speziell für den Anwendungsfall konstruiert, beispielsweise bei der Tomatenernte oder der Weinlese.

Im militärischen Bereich sind die drei „D“ der Robotik besonders offensichtlich: Dull, Dirty, Dangerous (langweilig, dreckig, gefährlich). Ein Großteil der Einsätze findet im Offroad-Bereich statt (Dirty). Die Gefährdungsreduktion kann durch die Verwendung unbemannter autonomer Systeme erreicht werden. Sowohl in Aufklärungs- als auch Logistikaufgaben – sei es ein längerer Konvoi im Nachschub oder ein einzelner Lastesel – werden weniger Soldaten in gefährlichen Bereichen (Dangerous) benötigt. Bei unbemannten Systemen kann zudem auf die teure und schwere Panzerung verzichtet werden, durch die ansonsten die mögliche Nutzlast signifikant reduziert wird.

Neben der Nutzung als vollautomatisiertes System können diese auch als Fahrerassistenzsystem zur kognitiven Entlastung bzw. zur Personaleinsparung genutzt werden, da der Fahrer neben der Fahraufgabe (Dull) nun auch Nebentätigkeiten ausführen kann [20]. Ein Lastesel kann neben dem autonomen Transport zwischen mehreren La-

gern auch für eine körperliche Entlastung des Soldaten durch den Transport von Marschgepäck sorgen.

Beim Katastrophenschutz definiert ebenso das unstrukturierte, unzugängliche Gelände die Anforderungen. Hier geht es um Erkundung und Bergung im Innen- und Außenbereich, z. B. nach einem Bergrutsch, Erdbeben oder Nuklearunfall.

Die Military European Land Robot Trial (M-ELROB) wurde als europäisches Pendant der DARPA-Wettbewerbe geschaffen. Die Szenarien sind motiviert aus Militär- und Katastrophenschutzperspektive, u. a. Aufklärung in einem beschädigten Gebäude, die Bergung von Verletzten oder der Lastentransport in *Konvoi* und *Mule*. Bei diesem Vergleich von Fähigkeiten der Robotikplattformen geht es den Veranstaltern jedoch weniger um die Kür eines Siegers, sondern vielmehr um das Aufzeigen der aktuellen Grenzen in realistischen Szenarien [21].

Die weiteren Abschnitte gliedern sich wie folgt: Abschnitt 2 gibt einen Überblick über die Wahrnehmungsmodule zur Objekt- und Umgebungserkennung, die als Grundlage für unsere Offroad-Systeme dienen. Darauf aufbauende Verhaltens- und Navigationsmodule zur Fahrzeugführung werden in Abschnitt 3 vorgestellt. In Abschnitt 4 werden die Versuchsfahrzeuge und die Ergebnisse aus den Wettbewerbsszenarien der M-ELROB 2016 präsentiert. Abschnitt 5 gibt neben einer Zusammenfassung einen Ausblick auf geplante weitere Arbeiten sowie die zukünftige Entwicklung in diesem Sektor allgemein.

2 Wahrnehmung

Die Wahrnehmung der Umgebung stellt einen essentiellen Aspekt aller FAS und Autonomiefunktionen dar. Gemeinsam ist den diversen Wahrnehmungsmodulen die Auswertung von Messdaten der unterschiedlichen Sensoren wie Farbkameras oder LiDAR, einerseits zur Auswertung der statischen Umgebung und andererseits zum Tracking von dynamischen Objekten über der Zeit. Dieses Abschnitt behandelt ausgewählte Verfahren, die für die im Weiteren behandelten Szenarien benötigt werden.

2.1 Umgebungsmodell

Das Umgebungsmodell beinhaltet Informationen über die statischen Eigenschaften des Fahrzeugumfelds. Es dient als einheitliche Datenschnittstelle zwischen der Sensorik und weiteren Prozessen wie der Wegerkennung und Pfadplanung.

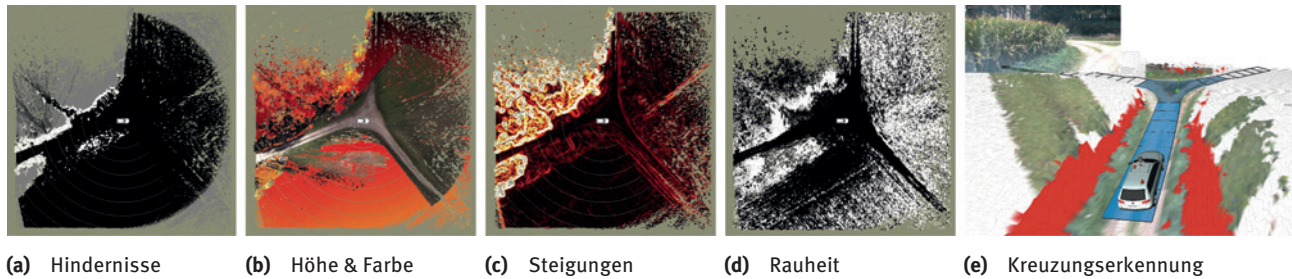


Abbildung 1: Einzelne Ebenen (a–d) des multimodalen $2\frac{1}{2}$ D-Umgebungsmodells [23] und Kreuzungserkennung (e) anhand des Umgebungsmodells [24, 25]: Detektierte Kreuzung mit teilweise verdeckten Ästen (blau) und Hypothese aus der Karte (grün).

Als Hauptsensorik kommen Tiefensensoren wie LiDAR-Sensoren oder Stereokamerasysteme zum Einsatz. Zusätzlich werden visuelle Informationen aus Kameras mit verschiedenen Spektralbereichen (Farb-, Nahinfrarot-, Wärmebildkameras) integriert. So wird eine vielschichtige $2\frac{1}{2}$ D-Umgebungskarte erzeugt, die aus Hinderniswahrscheinlichkeiten, Höheninformationen, Terrainsteigungen, „Rauheit“, Farbe, Temperatur etc. besteht (vgl. [22, 23]). Weitere Schichten, wie Straßenwahrscheinlichkeiten und Vegetation, können aus den existierenden Schichten abgeleitet werden. Einige Ebenen sind in Abbildung 1a–d dargestellt.

Eine möglichst lückenlose Darstellung der Umgebung ist wichtig für die Leistungsfähigkeit der weiteren Module wie der Pfadplanung. Das ist mit einer einzelnen Aufnahme eines Sensors nicht möglich: Stereokamerasysteme haben einen begrenzten horizontalen Blickwinkel und LiDAR-Sensoren eine geringe vertikale Auflösung. Daher akkumuliert das Umgebungsmodell die Daten über der Zeit, sodass es in jedem Zyklus mit neuen Sensordaten vervollständigt wird. Es wird jedoch keine globale Karte aufgebaut, sondern durch geeignete Algorithmen nur ein Bereich rund um das Fahrzeug als Gitterkarte abgebildet.

2.2 Weg- und Kreuzungserkennung

Eine Spurerkennung für markierte Straßen basiert meist auf dem Tracking von Kantenmerkmalen [2] im Kamerabild und ist heute in vielen kommerziellen Onroad-Systemen enthalten. Im Offroad-Bereich ist für die Spur- und Kreuzungserkennung der Einsatz divergenter Merkmale notwendig [22]. Ein Beispiel hierfür ist in Abbildung 1e gezeigt.

In den Farbbilddaten werden neben Kanten auch dynamisch ermittelte Farb- und Sättigungsinformationen sowie Histogramm-Rückprojektionen ausgewertet. Zusätzlich können aus dem Wärmebild Kanten- und Temperaturverteilungsinformationen extrahiert werden. Al-

ternativ zur Nutzung der 2D-Bilddaten können unsere Algorithmen derzeit die texturierten Zellen des $2\frac{1}{2}$ D-Umgebungsmodells aus Abschnitt 2.1 auswerten. Dazu kommen weitere Informationen aus dem Umgebungsmodell: Hindernisfreiheit, Steigungen, Zellhöhe sowie Zellklassifikationsergebnisse.

Diese Fülle an Merkmalen wird in einer Partikelfilterbasierten Architektur ausgewertet, um einerseits den Wegverlauf als Klotheide und andererseits die Form und Position von Abzweigungen zu detektieren und zu tracken [24, 25]. Die Ergebnisse dienen anschließend der Planungsebene zur Fahrzeugführung. Diese Wegerkennung kam in früheren Wettkämpfen bereits zum Einsatz [26].

2.3 Objekttracking

Onroad-Assistenzsysteme in Serien-PKW müssen im Straßenverkehr mit vielen dynamischen Objekten zurecht kommen, auch wenn z. B. für ACC nur ein einziges benötigt wird. Für die in diesem Artikel behandelten Offroad-Szenarien können Einschränkungen getroffen werden: Hier ist meist nur ein bestimmtes, vorher definiertes Objekt vorhanden, dieses muss jedoch mit hoher Robustheit getrackt werden. Alle getrackten Objekten werden unabhängig vom Algorithmus einheitlich durch eine orientierte Bounding-Box mit Geschwindigkeitsangabe beschrieben. Im Folgenden werden unterschiedliche Ansätze zum Tracking vorgestellt, wobei auf die Implementierungs- und Filterdetails nicht detailliert eingegangen wird. Anschließend stellen wir eine Fusionsebene vor, welche die Stärken der einzelnen Tracker kombiniert.

2.3.1 Kamerabasiertes Tracking

Modellbasiertes Fahrzeugtracking. Das modellbasierte Fahrzeugtracking verwendet spezielle 3D-Merkmalmodelle zum Tracking ausgewählter Führungsfahrzeu-

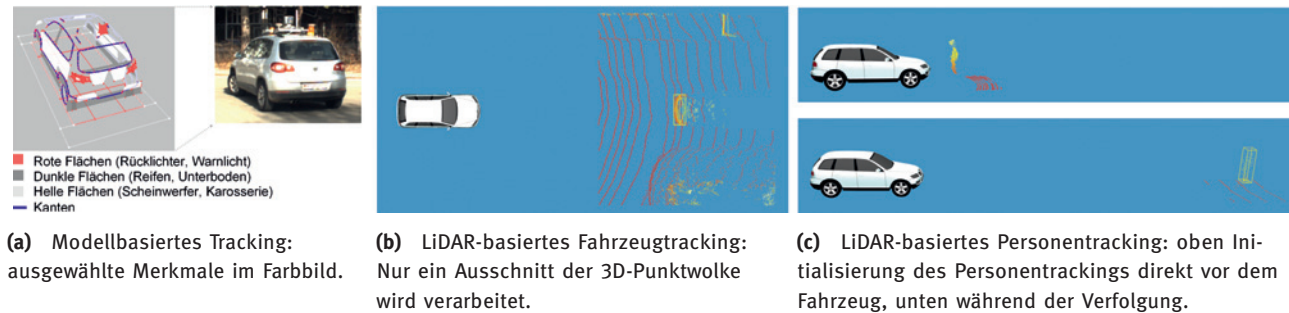


Abbildung 2: Drei verschiedene am Institut entwickelte Algorithmen zum Objekttracking. Beim LiDAR-basierten Tracking sind Objekte als Bounding-Box dargestellt (gelb, mit Bewegungsrichtung), unterlagert ist die 3D-Punktwolke (farbkodierte Höhe) visualisiert.

ge im Kamerabild. Mit einem Partikelfilter-basierten Ansatz werden die Partikel (Hypothesen der prädierten Zustände) in die Sensordaten projiziert und damit bewertet. Aus den bestbewerteten Partikeln ergibt sich der geschätzte Zustand. Die Modelle enthalten Merkmale zur Auswertung in unterschiedlichen Spektralbereichen, z. B. Kanten und Farbflächen für das Farbbild (vgl. Abbildung 2a), Temperaturbereiche für das Wärmebild und unterstützend Belegtheitsinformationen für eine nicht-akkumulierte $2\frac{1}{2}$ D-Belegtheitskarte. Diese Merkmale können in Abhängigkeit der Sensorausstattung des jeweiligen Versuchsträgers kombiniert werden.

Die Verwendung dieses modellbasierten Fahrzeugtrackings hat sich als sehr robust herausgestellt [27, 28], da hier bereits mehrere Sensoren fusioniert werden und sich durch das Modellwissen das gewünschte Fahrzeug gut von anderen Objekten, vor allem Vegetation, trennen lässt. Der große Nachteil dieses Verfahrens war bisher – vor allem aufgrund der zeitaufwendigen manuellen Modellerzeugung – die Einschränkung auf wenige bekannte Führungsfahrzeuge. Erste Ansätze zur automatischen Modellgenerierung ermöglichen eine flexiblere Fahrzeugauswahl und sind sehr vielversprechend [29], da sich der Aufwand von Tagen auf Minuten reduziert.

Kamerabasiertes Personentracking. Für das Mule-Szenario wurde ein Tracking einer einzelnen Person mittels eines aktiven Stereokamerasystems entwickelt. Ein genaues oder gelerntes Modell wird nicht benötigt, es werden lediglich obere Schwellwerte für Objektdimensionen angesetzt.

Der erste Schritt der Objektdetektion ist die Segmentierung der Bodenebene. Anschließend werden die Stereodaten, die nicht zum Untergrund gehören, anhand ihrer Bild- und 3D-Raumkoordinaten zu Objekten gruppiert.

Die Objekte gehen als Messungen in ein Erweitertes Kalman-Filter (EKF) ein, das neben der Position und Geschwindigkeit auch die Ausmaße des Objekts schätzt. Der




Abbildung 3: Personentracking mit einem Stereokamerasystem.

Zustand wird mit einem statischen Objekt geeigneter Größe in einem festgelegten Bereich vor dem Fahrzeug initialisiert. Anhand eines Constant Velocity (CV) Bewegungsmodells der Position und Orientierung erfolgt die Prädiktion. Eine Messung wird auf Basis der Position und Größe der 3D-Bounding-Boxen und mittels Daten des optischen Flusses mit dem Zustand assoziiert. Ausgewählte Schritte sind in Abbildung 3 dargestellt.

Das Stereokamerasystem ist auf einer um die vertikale Achse drehbaren Plattform montiert. Das ermöglicht es, die Kamera auf das getrackte Objekt auszurichten und auch in spitzen Kurven zuverlässig zu verfolgen.

2.3.2 LiDAR-basiertes Tracking

In den letzten Jahren wurde am Institut ein Trackingverfahren entwickelt [30, 31], das ein oder mehrere Objekte unterschiedlicher Klassen (Fahrzeuge, Personen) in der 3D-Punktwolke der LiDAR-Sensoren trackt. Zuerst werden die Punkte der hügeligen Bodenebene aus der Punktwolke entfernt (Ground Plane Segmentation) [32]. Anschließend werden die verbleibenden Punkte mittels Connected-Components-Analyse zu Detektionen gruppiert, die als Messungen für ein Unscented Kalman-Filter (UKF) verwendet werden.

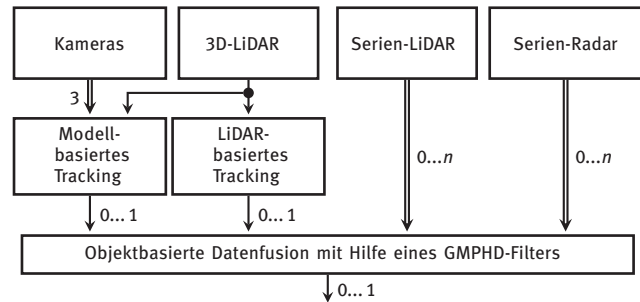
Vor dem Update des Zustands erfolgt die Assoziation der Detektionen zu den getrackten Objekten anhand eines Abstandsmaßes. Über die Abweichung von der erwarteten Ausdehnung werden dabei unplausible Messungen aussortiert. Bisher nicht zugeordnete Detektionen werden zur Erzeugung neuer Objekt-Tracks verwendet. Für spezielle Anwendungen kann das Filter auf ein bestimmtes Objekt (Fahrzeug oder Person) mit hinterlegter Ausdehnung reduziert werden. In diesem Fall wird bereits die Punktwolke auf die Umgebung der erwarteten Objektposition beschnitten, um Fehldetektionen zu vermeiden. Beispiele hierfür sind in Abbildung 2b und c zu finden.

Der Zustand des Objekts wird aufgrund der einfacheren Prozessmodelle in einem Dead-Reckoning-System beschrieben, Messungen werden in Roboter- bzw. Sensorkoordinaten verarbeitet. Das Tracking-Framework ist für unterschiedliche Objektklassen identisch, allerdings unterscheidet sich die Parametrierung des UKF in den verwendeten Prozess- und Messmodellen.


Für das Tracking von vorderachsgelenkten Fahrzeugen eignet sich das Einspurmodell als Prozessmodell. Dieses modelliert die Bewegung des Fahrzeugs entlang von Kreisbögen und verhindert eine Rotation im Stand.

Zur Prädiktion der Bewegung von Personen kommt ein Augmented Coordinated Turn-Modell (ACT) zum Einsatz. Dieses erlaubt unabhängige Vorwärts-, Seitwärts- und Drehbewegungen und ist damit für die Prädiktion von Fußgängern wesentlich besser geeignet als das Einspurmodell. Der Nachteil ist hierbei das größere Rauschen in der Ausrichtung der getrackten Bounding-Box.

Im Vergleich zum modellbasierten Fahrzeugtracking ist ein großer Vorteil des LiDAR-Trackings die große Unabhängigkeit vom Typ des Objekts, da kein explizites 3D-Merkmalmodell benötigt wird. In den Sensordaten ist jedoch oft nur eine Seite des Objekts sichtbar, dadurch ist seine Ausdehnung nur schlecht beobachtbar.



(a) Schematische Übersicht: Jeder Pfeil stellt die Anzahl der bereitgestellten Objekthypothesen dar.



(b) Fusionsergebnis (grün, mit Historie und präzidierte Fahrtrichtung) und Messungen der einzelnen Sensoren bzw. Tracker: LiDAR-Tracker (schwarz), Modellbasierter Tracker (blau), Serien-LiDAR (gelb), Serien-Radar (magenta).

Abbildung 4: Objektbasierte Datenfusion.

2.3.3 Objektbasierte Datenfusion

Neben den selbst entwickelten Tracking-Algorithmen wurden am Institut auch seriennahe Radar- und LiDAR-Sensoren evaluiert.

Die bisher gezeigten Verfahren sowie auch die seriennahen Sensoren haben Stärken und Schwächen in unterschiedlichen Bereichen. In einer nachgelagerten Ebene, der Objektbasierten Datenfusion (OBDF), werden daher die Ergebnisse aller Tracking-Systeme kombiniert, um ein möglichst präzises und gleichzeitig robustes Tracking zu erzielen (siehe Abbildung 4).

Die selbst entwickelten Algorithmen aus den Abschnitten 2.3.1 und 2.3.2 liefern je eine Objekthypothese (Position, Geschwindigkeiten, Größe inkl. Kovarianzen), während die seriennahen Sensoren jeweils eine Objektliste liefern. Diese enthalten Informationen zu allen detektierten bzw. getrackten Objekten, je nach Sensor ggf. mit Geschwindigkeits- und Größenschätzung sowie Kovarianz und Klassifikation. Da diese Sensoren keine Information über das tatsächliche Führungsfahrzeug haben, enthalten diese Objektlisten jedoch häufig eine große Anzahl an Fehldetektionen (Clutter), während das richtige Führungsfahrzeug nicht garantiert enthalten ist.

Vor allem durch die potentiell große Anzahl an Fehldetektionen stellte die Datenassoziation eine zentrale Herausforderung im Entwurf der OBDF dar. Eine elegante Lö-

sung dazu stellen Multi-Hypothesen-Tracker mit impliziter Datenassoziation dar. Unsere entwickelte OBDF basiert auf einem Gaussian Mixture PHD-Filter (Probability Hypothesis Density), wie es in [33] beschrieben ist. Pro Sensor kommt ein spezielles Messmodell zum Einsatz, das zum einen die jeweiligen Eigenschaften des Sensors selbst – bspw. den Sichtbereich oder die Messunsicherheiten – modelliert und zum anderen charakteristische Einflüsse bestimmter Führungsfahrzeugtypen auf die Messungen repräsentiert. So liefert beispielsweise ein niedrig montierter Sensor bei einem Führungsfahrzeug mit sehr großer Bodenfreiheit (etwa ein geländegängiger LKW) lediglich Messungen, die sich innerhalb des Fahrzeugs (auf Höhe dessen Achsen) befinden. Entsprechend müssen alle relevanten Kombinationen von Sensoreinbaulagen und Führungsfahrzeugtypen im Vorfeld vermessen und modelliert werden.

Die Eingangsdaten für die OBDF sind Ergebnisse von rekursiven Filtern und damit zeitlich korreliert. Obwohl dadurch die Anforderungen eines Kalman-Filters an die Messungen nicht erfüllt sind, wurden in der Praxis dennoch gute Ergebnisse erzielt.

Als dynamisches Modell für das Fusions-Filter hat sich ein kinematisches Einspurmodell mit der Geschwindigkeit, dem Gierwinkel, der Position des Führungsfahrzeugs sowie der Krümmung seiner aktuellen Spur als Zustände als gut geeignet erwiesen.

Um ein Ergebnis für nachfolgende Module zu erzeugen, wird aus den Multi-Objekt-Hypothesen des PHD-Filter diejenige mit dem höchsten Gewicht extrahiert und entsprechend eine einzige Schätzung kommuniziert.

Weitere Details zur OBDF finden sich in [34].

3 Verhalten und Navigation

Aufgabe des Verhaltens- bzw. Planungsmoduls ist es, generelle Verhaltensmuster abzubilden und somit die Bewegung des Fahrzeugs vorzugeben bzw. zu planen. Hierzu werden die Ergebnisse aus den Wahrnehmungsmodulen einbezogen, um z. B. Kollisionen mit Hindernissen zu vermeiden oder um auf lokale Veränderungen der Strecke zu reagieren.

Komplexeres Verhalten konsistent und nachvollziehbar zu implementieren erweist sich als außerordentlich schwierig. Üblicherweise wird hierbei ein hierarchischer Ansatz gewählt, bei dem die Verhaltens- bzw. Planungsseite aufgeteilt wird in übereinandergelagerte Ebenen mit jeweils spezialisierten Fähigkeiten, z. B. in eine überlagerte Verhaltensplanung, eine darunterliegende Navigationschicht, die die Ziele der Verhaltensplanung umsetzt, und

schließlich unterlagert einen Fahrzeugregler, der die geplanten Trajektorien der Navigation in Steuerkommandos an das Fahrzeug umsetzt.

Diese drei Ebenen werden im Folgenden betrachtet.

3.1 Verhalten

Die höchste Ebene auf der Verhaltensseite umfasst die Routenplanung sowie die Abbildung von Verhalten als Zustandsautomat. Nach einer kurzen Einführung digitaler Straßenkarten soll diese Verhaltensplanung näher betrachtet werden.

3.1.1 Digitale Straßenkarten

Um globale Routenplanung zu ermöglichen, werden digitale Straßenkarten benötigt. Zur Anwendung kommt hierbei das freie Kartenformat OpenStreetMap (OSM). Dadurch können einerseits von einer Onlinedatenbank bereitgestellte digitale Karten genutzt oder andererseits Karten mit Hilfe eines graphischen Editors selbst erstellt werden. In Offroad-Bereichen sind OSM-Karten oft wesentlich vollständiger und detaillierter als kommerziell erhältliche Karten, da viele Freiwillige laufend die Kartenbasis erweitern und aktualisieren.

Das Format selbst baut im Wesentlichen auf dem Punkt als geometrische Primitive auf, dieser wird in OSM *Node* genannt. Ein Punkt wird dabei definiert durch seine GNSS-Position und einen eindeutigen Bezeichner. Durch geeignete Zusammenfassung mehrerer solcher Nodes können übergeordnete Formen wie Straßenzüge oder Polygone erstellt werden. Weiterhin können die Elemente dieser Karte annotiert werden, um bestimmte Relationen wie z. B. benachbarte Spuren abzubilden.

Zur Anwendung kommt solch eine digitale Karte während der globalen Routenplanung. Dabei wird der kürzeste Weg von einem Startpunkt zu einem Zielpunkt durch die Karte gesucht. Der resultierende globale Pfad, also die Sequenz an Nodes, dient als Spurhypothese für die unterlagerte Trajektorienplanung (siehe Abschnitt 3.2.2). Der Pfad wird in diesem Kontext als Hypothese verstanden, da er in globalen GNSS-Koordinaten gegeben ist. Damit ist die Genauigkeit abhängig von der Lokalisierung und wird folglich durch die fehleranfällige GNSS-Positions-messung beeinflusst. Außerdem kann diese Karteninformation zur Generierung von Spur- bzw. Kreuzungshypothesen (siehe Abschnitt 2.2) genutzt werden.

3.1.2 Verhaltensplanung

Auf oberster Ebene der hierarchischen Verhaltensplanung kommt ein weiterer hierarchischer Ansatz zur Anwendung. Hierbei sollen generelle Verhaltensmuster abgebildet werden, welche in abgeleiteten Unterzuständen weiter spezialisiert werden. Die Verhaltensebene betrachtet also keine metrischen Koordinaten wie die Trajektorienplanung, sondern bestimmt abstraktere Verhaltensweisen und gibt somit der unterlagerten Navigation Ziele vor. Ziele sind zum Beispiel ein globaler Pfad, eine Liste an Landmarken oder eine Anforderung für einen Spurwechsel.

Die Schwierigkeit, Verhalten in Form eines hierarchischen Zustandsautomaten abzubilden, ergibt sich aus der stark zunehmenden Komplexität durch Hinzufügen neuer Zustände und den damit einhergehenden hohen kombinatorischen Möglichkeiten der Zustandsübergänge. Besondere Aufmerksamkeit muss hierbei der Definition der zulässigen Übergänge und den Zustandsübergangsbedingungen gewidmet werden.

3.2 Navigationsverfahren

Die meisten Navigationsverfahren zur Bewegungsplanung lassen sich in drei Kategorien einteilen [35]: Bei der *reaktiven Navigation* wirkt die wahrgenommene Umgebung unmittelbar auf die Fahrzeugführung. Ein Beispiel sind die auf Hindernisse ansprechenden *Tentacles* [36], die von 2007 bis 2012 für erfolgreiche Wettbewerbsteilnahmen des Instituts verwendet wurden. Konträr dazu ist die weit verbreitete *globale Navigation* auf Trajektorien [26, 37], bei der Fahrzeugführung und Wahrnehmung stark separiert sind. Ein Mittelweg ist die *geführte Navigation*, z. B. die Nutzung der Relativlage zur getrackten Fahrspur als Eingangsgröße für die Querregelung [3]. Auch Kombinationen aus mehreren Navigationsarten sind möglich, z. B. die Verwendung von globaler Information wie GNSS in reaktiven Verfahren [38], oder die situationsabhängige Umschaltung zwischen geführter und globaler Navigation.

Im Folgenden werden zwei Navigationsverfahren unterschiedlicher Kategorien vorgestellt, die für die in Abschnitt 4 beschriebenen Wettbewerbsszenarien benötigt werden.

3.2.1 Spurgenerierung im Konvoi

Die Spurgenerierung für die Verfolgung eines anderen Fahrzeugs im Konvoi oder einer Person ist ein Beispiel für die *geführte Navigation*. Ein Objekttracker aus Ab-

schnitt 2.3 liefern ein Objekt, dessen Position in ein globales Koordinatensystem in einem sprungfreien Dead-Reckoning-Koordinatensystem transformiert wird. Das Planungsmodul bestimmt mit Hilfe eines simulierten Pure-Pursuit-Reglers [39, 40] aus der Historie von bisherigen Objektpositionen eine durch das Ego-Fahrzeug befahrbare Trajektorie.

Dem Fahrzeugregler dient diese weitgehend vom getrackten Objekt vorgegebene Trajektorie zur Querführung [41]. Abstand und Geschwindigkeit des Objekts werden zur Längsführung verwendet. Damit wird eine Verfolgung des selektierten Objekts – Fahrzeug oder Person – gewährleistet.

3.2.2 Trajektorienplanung in metrischen Karten

Bei der *globalen Navigation* entlang einer vom Verhalten vorgegebenen Route kommt ein auf Hybrid A* [42] basierender Algorithmus zum Einsatz. Dieser liest diverse Gitterkarten des $2\frac{1}{2}$ D-Umgebungsmodells ein (siehe Abschnitt 2.1), deren Zellen Informationen wie Hinderniswahrscheinlichkeit, Steigung, Vegetationswahrscheinlichkeit und Straßenwahrscheinlichkeit enthalten. Anhand dieser Merkmale sucht das Planungsmodul nun nach der kostengünstigsten hindernisfreien Trajektorie, die das Fahrzeug in Richtung Ziel führt. Ein simuliertes Fahrzeugmodell stellt hierbei sicher, dass die kinematischen und dynamischen Beschränkungen des Ego-Fahrzeugs (maximaler Lenkeinschlag sowie maximale Quer-/Längsbeschleunigung) beachtet werden.

In Abbildung 5 ist beispielhaft eine Hinderniskarte mitsamt potentiellen Trajektorien und der ausgewählten




Abbildung 5: MuCAR-3 navigiert durch ein Waldgebiet. Befahrbare Bereiche sind schwarz dargestellt, Hindernisse rot und verdecktes Gebiet grau. Aufgrund von GNSS- und/oder Kartenfehlern liegt die globale Route (cyan) in nicht befahrbarem Gebiet. Die 100 kostengünstigsten Trajektorien im Suchbaum des A*-Planers sind hier weiß dargestellt, die ausgewählte beste in Grün.

optimalen Lösung zu sehen. Details zu dem hier beschriebenen Algorithmus finden sich in [26, 43].

3.2.3 Regelung

Die Fahrzeugregelung ist zweigeteilt. Die sog. High-Level Regelung nutzt die bereitgestellten Trajektorien sowie die eigene Relativlage zur selbigen als Eingang für austauschbare Regleralgorithmen. Diese stellen Referenzwerte für Geschwindigkeit und Lenkwinkel bereit. Zur Kompensation von Totzeiten in der Regelkette wird zusätzlich eine präzisierte Relativlage im Regler genutzt. Der Low-Level-Teil der Reglerarchitektur sorgt für das Einhalten der vorgegebenen Referenzwerte sowie die fahrzeugspezifische Ansteuerung der Aktorik.

4 Evaluierung und Ergebnisse


Die M-ELROB wird derzeit alle zwei Jahre veranstaltet und bietet unterschiedliche Szenarien zur Demonstration und Bewertung der Leistungsfähigkeit unterschiedlicher Roboter. Neben In- und Outdoor-Aufklärungsaufgaben für kleinere Fahrzeuge gab es 2016 zwei Szenarien, *Konvoi* und *Mule*, die auch für größere Versuchsträger geeignet waren. Diese ziehen wir zur Bewertung der Leistungsfähigkeit der entwickelten Assistenz- und Autonomiefunktionen heran. Die M-ELROB 2016 fand auf dem Katastrophenübungsplatz *Tritolwerk* in der Nähe von Wiener Neustadt/Österreich statt.

Bevor wir auf die Ergebnisse in den beiden Szenarien eingehen, geben wir einen kurzen Überblick über die verwendeten Versuchsträger.

4.1 Versuchsträger

Die beiden Versuchsträger des Instituts sind MuCAR-3 (Munich Cognitive Autonomous Robot Car 3rd Generation) und MuCAR-4, ein VW Touareg und ein VW Tiguan (siehe Abbildung 6b). Beide sind mit vollständigen Drive-by-Wire-Einbauten sowie den zugehörigen Schnittstellen- und Rechnermodulen zur Ansteuerung von Gas-/Brems-/Lenk- und Getriebeaktorik ausgestattet.

Zur Wahrnehmung der Umwelt sind die Fahrzeuge mit teils umfangreicher Sensorik ausgestattet: Kameras in unterschiedlichen Spektralbereichen (Farbe, NIR, FIR) und unterschiedlicher Brennweite, zum Teil als Stereo-System ausgelegt, ein Velodyne 3D-LiDAR-Sensor zur Rundumsicht sowie seriennahe Radar- (Radio Detection And Ran-



(a) Luftbild mit gefahrenem Weg (blau), vorgegebenen Wegpunkten (gelb) sowie kartierten Objekten (orange)



(b) Team MuCAR in einer Engstelle: MuCAR-4 fährt manuell, MuCAR-3 folgt autonom. Quelle: www.elrob.org



(c) Der TULF (rechts) und sein Führungsfahrzeug stoppen an einem dynamischen Hindernis. Quelle: www.heise.de

Abbildung 6: Konvoi-Szenario der M-ELROB 2016: (a) gibt einen Überblick über die Wettbewerbsstrecke, (b) und (c) geben Eindrücke von der Strecke und Hindernissen.

ging) und LiDAR-Sensoren für die Straßenfahrt. Alle in den vorherigen Abschnitten beschriebenen Algorithmen werden auf einem leistungsfähigen Linux-Rechner ausgeführt.

Die Fahrzeuge sind neben der Serienfahrzeugsensorik mit hochwertiger Inertialsensorik sowie RTK-GNSS-Empfängern ausgestattet. Diese dienen der Lokalisierung des Fahrzeugs und einer als Grundlage für alle Wahrnehmungs- und Planungsalgorithmen dienenden präzisen Eigenbewegungsschätzung.

Ein weiterer Versuchsträger ist der TULF (Technologie-träger Unbemanntes Landfahrzeug), ein geländegängiger militärischer LKW (siehe Abbildung 6c). Dieser wurde mit Industriepartnern im Rahmen mehrerer vom Bundesamt für Ausrüstung, Informationstechnik und Nutzung der Bundeswehr (BAAINBw) beauftragter Studien aufgebaut [44]. Der TULF verfügt über ein ähnliches Sensorkonzept wie MuCAR-3, auch wenn einzelne Sensortypen unterschiedlich sind.

4.2 M-ELROB 2016 – Konvoi

Im Konvoi-Szenario der M-ELROB musste ein Konvoi – bestehend aus mindestens zwei Fahrzeugen, von denen maximal eines manuell gefahren wird – einen Parcours über Wiesen, Feld- und Schotterwege absolvieren. Der Fahrer des Führungsfahrzeugs erhielt dazu eine Karte mit Wegpunkten, die in der korrekten Reihenfolge passiert werden mussten. Das Folgefahrzeug MuCAR-3 folgte autonom. Innerhalb eines Zeitlimits von 45 min konnte der Parcours für eine bessere Bewertung mehrfach absolviert werden. Weitere Punkte für die Bewertung lieferte die Nebenaufgabe aus dem Bereich Aufklärung: „Finde orange Gefahrguttafeln, kartiere diese und liefere Bilder ab“.

An dieser Stelle sei angemerkt, dass in diesem Szenario alle Teams aus Sicherheitsgründen in der Kategorie „Supervised Autonomy“ gestartet sind, bei denen die autonomen Fahrzeuge mit Sicherheitsfahrer und Schiedsrichter besetzt waren. Jegliche Eingriffe führten zu negativer Bewertung.

In jeder Runde tauchten andere Hindernisse auf, die ein Abweichen von der direkten Wegeverbindung erforderten. Engstellen wie in Abbildung 6b erforderten präzises Navigieren, dynamische Hindernisse wie die Fahrspur versperrende Fußgänger in Abbildung 6c einen Stopp des Konvois. Vollständige Blockaden des Weges erforderten mehrmals Ausweichrouten durch hohes Gras, einmal auch ein autonomes Zurückstoßen des kompletten Konvois. Hierbei wurde MuCAR-3 automatisiert „zurück geschoben“: es fuhr den gespeicherten Weg rückwärts solange das Führungsfahrzeug rückwärts fuhr, und korrigierte die gespeicherte Spur.

Eine Übersicht über die Strecke ist in Abbildung 6a gegeben.

Auswertung. Team MuCAR ging mit vier absolvierten Runden ohne einen einzigen Eingriff des Sicherheitsfahrers sowie mit Zusatzpunkten aus der Aufklärung als Sieger hervor. Detaillierte Ergebnisse [45] und das zugrundeliegende Bewertungsschema finden sich beim Veranstalter¹ sowie in [34].

Die in der M-ELROB 2016 zum ersten Mal eingesetzte Objektbasierte Datenfusion (OBDF) hat sich bewährt, die Einflüsse der Witterung auf einzelne Sensoren – z. B. tief stehende Sonne auf die Kameras oder Staub auf dem LiDAR – hatten so kaum noch Einfluss. Wie immer in der Forschung besteht in allen Trackingalgorithmen noch Verbesserungspotenzial.

Im derzeitigen Entwicklungsstand ist allerdings dem menschlichen Fahrer des Führungsfahrzeugs noch eine sehr hohe Bedeutung gegeben. Dieser muss seine Fahrweise anpassen, da ihm das autonome Fahrzeug spurtreu folgt, ohne die restliche Umgebung zu beachten. Deshalb muss er Hindernissen passend ausweichen und darf aus Kurven nicht zu stark herausbeschleunigen.

TULF. Unser Institut war im Konvoi-Szenario auch am Team Smart Military Vehicles (SMV) beteiligt, das mit dem Versuchsträger TULF (siehe Abbildung 6c) ins Rennen ging und den zweiten Platz vor Team Austrian Technology erzielte. Für die M-ELROB trugen wir Module zur Eigenbewegungsschätzung sowie das komplette Fahrzeugtracking bei, während Pfadplanung und Regelung durch andere Teammitglieder erfolgte. Im Folgenden stellen wir die Unterschiede zu MuCAR-3 in den Algorithmen und die erzielten Ergebnisse kurz vor.


Größere Abstände und vor allem scharfe Kurven sorgen immer wieder für eine Verdeckung des Führungsfahrzeugs in den Sensoren des TULF. Die OBDF nutzt zum einen, analog zu MuCAR-3, die oben näher beschriebenen lokalen Sensordaten, zum anderen in dieser Applikation auch Informationen aus einer Fahrzeug-Fahrzeug-Kommunikation, um trotz Sichtverlust ein robustes Tracking sicherzustellen.

Im Offroad-Betrieb, vor allem im Wald, treten in der Regel große GNSS-Offsets bei beiden Fahrzeugen auf. Diese langsam veränderliche Störung kann im Normalbetrieb über die anderen Sensoren beobachtet und somit vorab mitgeschätzt werden. Bei Sichtverlust wird die hiermit korrigierte GNSS-Position als Messung verwendet. Zusätzlich werden die übermittelte Geschwindigkeit sowie die Fahrtrichtung immer im PHD-Filter als Messung verarbeitet, da diese nicht vom GNSS-Offset beeinflusst werden.

Vergleicht man die Einflüsse der einzelnen Sensoren, so fallen vor allem viele Fehldetektionen des Radar-Sensors auf. Aufgrund seiner Größe ist der TULF gerade bei Hindernissen weniger manövrierfähig als ein PKW, dies ist mit ein Grund für die Platzierung hinter Team MuCAR.

Große Anteile der auf der M-ELROB mit dem TULF demonstrierten Funktionalitäten wurden zuvor erfolgreich in der BAAINBw-Studie StrAsRob (Straßentransport mit Assistenzfunktionen von Robotern) integriert und offroad demonstriert. Bei StrAsRob lag der Fokus allerdings weniger auf voller Autonomie sondern eher auf einer Assistenzfunktion zur temporären Entlastung des Fahrers [20] während der Konvoifahrt.

¹ <http://www.elrob.org/elrob-2016-results>



(a) Luftbild der Strecke im Tritolwerk, überlagert mit einem Wegennetz (magenta), der Spur der verfolgten Person (rot) und der gefahrenen Spur (gelb). Die beiden Lager A und B (gelb) sowie die Blockaden X (grün) sind markiert.



(b) MuCAR-3 folgt im Teach-In einer Person.



(c) Tonnen als Blockade X_1 zwingen zum Umlanen

Abbildung 7: Mule-Szenario der M-ELROB 2016: (a) zeigt eine annotierte Karte, (b) und (c) zeigen Situationen aus beiden Phasen des Szenarios.

4.3 M-ELROB 2016 – Mule

Das Mule-Szenario der M-ELROB ist in der Literatur als *Teach-and-Repeat* bekannt. Dieses Szenario gliedert sich im Allgemeinen in zwei Schritte, wobei im ersten Teil ein autonomes Fahrzeug einen Weg zwischen zwei Orten erlernt (engl. *Teach-In*). Im zweiten Schritt soll das Fahrzeug wiederholt autonom zwischen beiden Positionen pendeln (engl. *Shuttle*). Im Zustandsautomaten der Verhaltensebene werden die zwei Phasen, das *Teach-In* und das *Shuttlen*, als eigene Überzustände implementiert. Diese Fähigkeiten werden in abgeleiteten Unterzuständen weiter spezialisiert. So besitzt der Zustand *Shuttle* unter anderem als Unterzustände das Verhalten Pfadfolgen und Neuplanen als Form der Fehlerbehandlung, wenn kein weiterer Fortschritt auf der zu fahrenden Route mehr erkennbar ist. Dies passiert bei einer Blockade des Weges durch ein Hindernis. Hier kann die vorher beschriebene digitale Karte benutzt werden, um eine Alternativroute zum Ziel zu finden.

Der Wettbewerb fand auf einem Gelände mit Wiesen, Feld- und Schotterwegen statt, eine Übersicht ist in Abbildung 7a gegeben. Die folgenden Abschnitte detaillieren die beiden Phasen *Teach-In* und *Shuttle*.

4.3.1 Teach-In

In der Teach-In-Phase folgt das Fahrzeug einem Menschen, der in den Sensordaten detektiert und getrackt wird, von Lager A zu Lager B und kartiert diesen Weg als Grundlage für das spätere Pendeln.

Für das Personen-Tracking kam im Wettbewerb der LiDAR-basierte Tracker aus Abschnitt 2.3.2 zum Einsatz. Um eine Initialisierung des Trackers auf den richtigen Menschen auch bei dichter Vegetation zu gewährleisten, wurde hierfür nur ein Ausschnitt der 3D-Punktwolke vor dem Fahrzeug verwendet (vgl. Abbildung 2c). Die Spurgernerierung aus Abschnitt 3.2.1 erzeugte aus den geschätzten Objektposen die Trajektorien für die Regelung.

Der so erzeugte Pfad wurde einerseits zum Folgen der Person während des Teach-In verwendet. Andererseits speicherte die Verhaltenskomponente diesen Pfad als optimalen Verbindungsweg sowie ergänzend die Position der beiden Basislager, um im folgenden Shuttle-Modus wiederum Spurrhypothesen für die unterlagerte Trajektorienplanung aus Abschnitt 3.2.2 zu liefern.

Zu beachten war, dass bei einem fehlerhaften Verhalten der Führungsperson das Fahrzeug durch diese wieder automatisiert „zurück geschoben“ werden konnte. Diese Situation – fahre den gelernten Weg rückwärts, solange die Person zurückgeht – war zu detektieren und der Pfad entsprechend zu korrigieren, anstatt weiter neue Pfadpunkte an das Ende anzuhängen.

Der Pfad wurde als Sequenz von globalen GNSS-Koordinaten im Abstand von 1 m abgespeichert. Damit ist er unempfindlich gegenüber der Drift in einem Dead-Reckoning-System, welches Fehler der Odometrie über der Zeit immer weiter aufintegriert und damit die Differenz gegenüber dem globalen System stetig größer wird. Der Pfad war zwar global gegeben und damit anfällig gegenüber GNSS-Fehlern, durch Wahrnehmung und reaktive Trajektorienplanung waren wir aber trotzdem in der Lage, befahrbaren Untergrund zu detektieren und dem korrekten Straßenverlauf zu folgen.

Anzumerken ist weiterhin, dass im Gegensatz zum späteren Shuttlen während der Teach-In-Phase keine Hindernisvermeidung angewendet wurde, d. h. dass die Führungsperson verantwortlich dafür war, einen für das Fahrzeug fahrbaren Weg abzulaufen. So musste die Person von etwaigen Hindernissen, die in die Fahrspur ragen, einen

Abstand entsprechend der Fahrzeugbreite halten. Weiterhin konnte die abgefahrte Trajektorie an Kreuzungen optimiert werden, wenn die Person Kurvenradien entsprechend dem möglichen Lenkwinkel des Fahrzeugs einhielt.

Am Ziellager *B* angekommen, blieb die getrackte Person für einen bestimmten Zeitraum bewegungslos stehen. Dies diente im Zustandsautomaten zur Detektion, dass der gewünschte Zielpunkt erreicht war und der Shuttlevorgang beginnen konnte.

4.3.2 Shuttle

Während der Teach-In-Zustand dafür verantwortlich ist, das Anlernverhalten abzubilden und die Positionen der Lager und den Pfad abzuspeichern, implementiert der Shuttle-Zustand das darauffolgende Pendeln.

Aufgrund der Szenariodefinition mit möglichen dynamischen Routenänderungen kommt der Fehlerbehandlung eine besondere Bedeutung zu und wurde deshalb als weiterer Unterzustand eingeführt. Als Fehler wird hier verstanden, dass das Fahrzeug auf der Route keinen Fortschritt mehr erreicht, zum Beispiel bei einer Blockade des Weges durch Hindernisse. Nach Ablauf einer vordefinierten Zeitspanne im Stillstand wechselt das Verhalten vom *Drive*-Zustand in den *Replan*-Zustand. In diesem Zustand wird die aktuelle Fahrzeugposition und die Position des anzusteuern Lagers dazu benutzt, eine Alternativroute zu finden. Dazu werden in der digitalen Straßenkarte aus Abschnitt 3.1.1 zu diesen Positionen die nächstgelegenen Wege gesucht, wobei das Kartensegment vor dem Fahrzeug für die Routenplanung gesperrt wird. Dann kann durch Anwendung klassischer Suchalgorithmen auf Graphen ein alternativer kürzester Weg von Start zu Ziel gesucht werden. Dieser so gefundene Weg wird wieder als Spurhypothese in Form eines globalen Pfades an die unterlagerte Trajektoriengenerierung kommuniziert.

4.3.3 Auswertung

Im Mule-Szenario starteten wir ebenfalls in der Kategorie „Supervised Autonomy“, mit denselben Regeln für manuelle Eingriffe wie im Konvoi-Szenario. Im Vorfeld der M-ELROB wurden zwei parallele Zweige entwickelt: einerseits auf rein visueller Basis mit mehreren Stereokameras, und andererseits mit fusionierten Messdaten aus LiDAR und Kameras. Während im Teach-In beide Varianten gute Ergebnisse lieferten, erwies sich die Fusionsvariante im Shuttle bei der Erkennung von kleineren Hindernissen

und Vegetation als robuster. Daher kam im Wettkampf nur letztere zum Einsatz.

Im Teach-In konnte MuCAR-3 der laufenden Person folgen und die Strecke zu Lager *B* kartieren. Die ersten beiden Shuttlevorgänge zu Lager *A* und zurück zu *B* erfolgten vollkommen problemlos auf der angelernten, hindernisfreien Strecke. Bei der nächsten Wiederholung wurde ein Wegsegment X_1 durch Tonnen blockiert, so dass MuCAR-3 kurz rangierte (siehe Abbildung 7c) und dann eine Alternativroute plante. Dort scheiterte die Durchfahrt allerdings an höherer Vegetation, die als Hindernis angesehen wurde, so dass der Sicherheitsfahrer diesen kurzen Abschnitt manuell umfahren musste. Nach der nächsten Wende bei Lager *A* wurde MuCAR-3 zum Verhängnis, dass aufgrund von X_1 die nördliche Route noch gesperrt war, und die geplante südliche Route durch unpassierbares Gelände führte (siehe Abbildung 7a). Es folgten ein weiterer Eingriff und manuelle Fahrt – vorbei an einer Blockade X_2 im hohen Gras – zu Lager *B*. Dort wurde der normale Rückweg zu *A* mit Blockade X_3 gesperrt, diese wurde korrekt erkannt und eine südliche Ausweichroute geplant. Teilweise war dieser Weg ebenfalls mit höherem Gras bewachsen, hier – und kurz darauf bei der Durchfahrt einer hoch bewachsenen Wiese – kam es zu erneuten Eingriffen des Sicherheitsfahrers. Bei Erreichen von Lager *A* nach ca. 21 min wurde beschlossen, das Zeitlimit von 30 min nicht auszunutzen und stattdessen die Messdaten zu übertragen.

Vergleicht man die Resultate mit den anderen Teams, so war MuCAR-3 in der Bewertung [45] um mehr als 50% besser als die beiden Nächstplatzierten und ging auch aus dem Mule-Szenario – trotz der aufgetretenen Schwierigkeiten – als Sieger hervor. Kein anderes Team schaffte es weiter als zur erkannten ersten Blockade, und niemand kam ohne Eingriff des Sicherheitsfahrers bzw. Operators aus.

Zusammenfassend lässt sich zum Mule-Szenario sagen, dass sich die Behandlung von Blockaden im Verhalten als absolut notwendige Erweiterung gegenüber der vorherigen M-ELROB 2012 herausgestellt hat, hier allerdings noch Verbesserungspotential besteht. Wie im Vorfeld befürchtet, war höheres Gras auf dem Weg eine Herausforderung, hier versprechen wir uns künftig Verbesserung durch Klassifikationsverfahren für den Untergrund. Die für das Umplanen verwendete Karte wurde vor den Wettkämpfen auf Basis von Luftbildern erstellt, dabei wurden auch Fahrspuren durch Wiesen mit aufgenommen. Einerseits war dies korrekt und hat das Fahrzeug auf die vom Veranstalter gewünschte Route bei X_1 und X_2 geleitet, andererseits führte im südöstlichen Bereich eine geplante Route durch im Laufe der Jahre höher gewachsene Vegetation und war nicht gewünscht.

5 Zusammenfassung und Ausblick

In diesem Artikel haben wir zwei Assistenz- und Autonomiefunktionen für den Einsatz abseits der Straße sowie die zugrunde liegenden Wahrnehmungs- und Planungsmodul vorgestellt. Im Rahmen der M-ELROB 2016 konnten diese erfolgreich demonstriert und mit anderen Wettbewerbsteilnehmern verglichen werden.

Aufgrund der M-ELROB-Szenarien und vieler Testfälle im Vorfeld wurde an einigen Stellen Verbesserungspotential aufgedeckt. Im Mule-Szenario war – wie erwartet – höheres Gras auf einigen Wegen eine Herausforderung, da dieses als Hindernis erkannt wurde. Hier versprechen wir uns entscheidende Fortschritte durch eine bessere Klassifikation der Oberflächen, die u. a. zwischen befahrbarer und unbefahrbarer Vegetation unterscheidet. Unsere neue Planungs- und Verhaltensarchitektur besitzt ebenfalls noch Verbesserungspotential, z. B. durch die Berücksichtigung von dynamischen Objekten in der Trajektorienplanung.

Da die Streckenführung im Konvoi-Szenario in dieser M-ELROB auch für LKW geeignet war, waren die Engstellen mit unseren PKW gut zu meistern. In den unterschiedlichen Trackern besteht Entwicklungspotential, z. B. eine Klassifikation, Rauschreduktion und bessere Größenschätzung im LiDAR-basierten Tracking, die in schwierigeren Parcours erforderlich wird. Das modellbasierte Tracking wird durch die Erweiterung auf dynamisch gelernte 3D-Fahrzeugmodelle [29] erhebliche Flexibilität gewinnen.

Langfristig sehen wir weiterhin den Bedarf, die bisher notwendigen kurzen Abstände zwischen den Fahrzeugen wesentlich aufzuweiten, so dass ein direktes Folgen nicht mehr nötig ist und statt dessen neue Navigationsverfahren zum Einsatz kommen müssten. Einen Ansatz hierzu stellen wir im folgenden Abschnitt 5.1 vor.

Betrachtet man die zukünftige Entwicklung der Assistenz- und Autonomiefunktionen allgemein, so sehen wir unterschiedliche Zeithorizonte im Onroad- und Offroad-Bereich. Ein Ausblick ist in Abschnitt 5.2 zu finden.

5.1 Landmarkenbasierte Navigation am Beispiel Konvoi

Ein möglicher Lösungsansatz für weiter aufgefächerte Konvois ist die landmarkenbasierte Navigation, die in Abbildung 8 abstrahiert dargestellt ist.

Dabei ist jedes Fahrzeug für sich in der Lage, Landmarken zu erkennen. Bei den Landmarken kann es sich einerseits um von Menschen erkennbare Landmarken wie Bäu-




Abbildung 8: Landmarkenbasierte Navigation: Jedes Fahrzeug kommuniziert erkannte Landmarken wie Bäume und Kreuzungen an weitere Fahrzeuge im Umkreis, die daraus eine topologische Karte erstellen und diese zur eigenen Navigation nutzen.

me und Sträucher [47] sowie Wegsegmente oder Kreuzungen [24, 25] handeln, andererseits können auch artifizielle, allein durch Deskriptoren beschriebene Landmarken zum Einsatz kommen [46].

Die Fahrzeuge kommunizieren erkannte Landmarken bidirektional im Konvoi, parallel wird pro Fahrzeug eine topologische Karte der erkannten und empfangenen Landmarken erzeugt. Der Vorteil des landmarkenweisen Abgleichs gegenüber dem Abgleich einer kompletten Karte ist die Eignung auch für instabile Kommunikation. Zudem können Informationen mehrerer Fahrzeuge zu einer Karte verarbeitet werden. Aufgrund der höheren Reichweite und Robustheit setzen wir auf einfachen Datenfunk mit 9600 bit/s anstelle von WLAN, d. h. die Übertragung komplexerer Landmarken oder Datenstrukturen ist nicht möglich.

Für diesen Ansatz ist das Tracking des eigenen Führungsfahrzeugs weniger wichtig, stattdessen ist ein gutes Tracking sämtlicher dynamischer Objekte im Umfeld erforderlich, um anschließend in der Trajektorienplanung berücksichtigt zu werden.

Mit Hilfe der topologischen Karte erfolgt die Lokalisierung der einzelnen Fahrzeuge, allerdings nicht in einer für die automatisierte Spurführung geeigneten Präzision, sondern vor allem für Richtungsentscheidungen wie „an der Kreuzung mit der folgenden Baumreihe links abbiegen“. Für die Navigation kommen lokale Wahrnehmungs- und Planungsalgorithmen (vgl. Abschnitt 2.2 und Abschnitt 3.2.2) zum Einsatz: anhand von erkannten Wegsegmenten und Kreuzungen sowie statischen Hindernissen und dynamischen Objekten wird die Solltrajektorie berechnet und der Fahrzeugregelung übergeben.

5.2 Zukünftige Entwicklung

Abschließend wollen wir einen Ausblick auf die allgemeine Fortentwicklung in den kommenden Jahren geben.

Auf Autobahnen setzt sich die laufende Entwicklung fort: Nach den Plänen der Automobilindustrie werden noch in diesem Jahrzehnt erste hoch- und vollautomatisierte PKW und LKW anzutreffen sein. Die Änderungen der gesetzlichen Grundlagen wurden im Frühjahr 2017 beschlossen [48–50]. Bei diesen Fahrzeugen muss der Fahrer das System nicht mehr dauerhaft überwachen und kann sich temporär anderen Aufgaben widmen, bleibt allerdings in der Verantwortung. Das System hat den Fahrer aber rechtzeitig zu warnen, wenn dieser eingreifen muss.

Autonome Fahrzeuge, bei denen völlig auf einen Fahrer verzichtet wird und es nur noch Passagiere gibt, sind demnach in Deutschland noch nicht zulassungsfähig. Sobald Prototypensysteme mit Sicherheitsfahrer ihre Robustheit hinreichend bewiesen haben, ist mit einer Anpassung der gesetzlichen Rahmenbedingungen – vermutlich in den 2020er Jahren – zu rechnen. Sie werden zuerst im langsamen Geschwindigkeitsbereich anzutreffen sein, so dass als erste Anwendungen beispielsweise das Valet-Parken oder autonome Taxi-Dienste, wie sie Uber oder Lyft entwickeln, zu erwarten sind. Grundlage für diese Systeme sind hochpräzise Karten zur Lokalisierung, deren Erstellung und Bereitstellung derzeit nur in örtlich begrenzten Gebieten realistisch erscheint.

Im Offroad-Bereich wird sich der Trend zur Automatisierung ebenfalls weiter fortsetzen. Die meisten Aktivitäten in der Landwirtschaft finden auf privatem Grund und nicht im öffentlichen Straßenverkehr statt, daher ist hier eine Ausweitung der Autonomie rechtlich problemlos möglich.

Im militärischen Bereich wurde der in den USA per Gesetz geforderte Fortschritt [4] bei weitem nicht erreicht [51]. Ursache sind neben Budgetkürzungen auch technologische Herausforderungen in komplexem Gelände. Im Gegensatz zum zivilen Onroad-Markt kann man sich hier nicht auf hochgenaue Karten verlassen.

Auch außerhalb der USA wird weiter an der Automatisierung im militärischen Bereich gearbeitet, der Schwerpunkt liegt hier allerdings derzeit vor allem auf kleineren Systemen zur Aufklärung oder Entschärfung. Automatisierte LKW wie der TULF werden vermutlich erst in den späten 2020er Jahren in Serie gehen.

Danksagung: Für die Beiträge zum Erfolg auf der M-ELROB 2016 gebührt vielen weiteren Mitstreitern Dank: für das Team MuCAR allen Mitarbeitern des Instituts für Technik Autonomer Systeme, und für das Team Smart Military

Vehicles (SMV) den Kollegen von Diehl Defence und Hentschel System GmbH. Nicht zuletzt ist den Ausrichtern der M-ELROB 2016, dem Fraunhofer FKIE und dem österreichischen Bundesheer, zu danken. Ohne ihre größtenteils ehrenamtliche Arbeit wären solche Wettbewerbe nicht möglich.

Finanzierung: Die Autoren bedanken sich beim Bundesamt für Ausrüstung, Informationstechnik und Nutzung der Bundeswehr (BAAINBw) für die Finanzierung von großen Teilen ihrer Forschung sowie der Deutschen Forschungsgemeinschaft (DFG).

Videos: Auf der Webseite <http://www.mucar3.de/elrob2016> stellen wir Videos zum Konvoi-Szenario der M-ELROB 2016 sowie zur Funktionsweise des Mule-Systems bereit.

Literatur

1. C. Thorpe, M. Hebert, T. Kanade, und S. Shafer, „Toward Autonomous Driving: The CMU Navlab. Part II: System and Architecture“, *IEEE Expert*, Bd. 6, Nr. 1, S. 44–52, Aug. 1991.
2. E. D. Dickmanns und A. Zapp, „Autonomous High Speed Road Vehicle Guidance by Computer Vision“, in *Proc. 10th IFAC World Congress*, Bd. 4 (preprint), 1987, S. 232–237.
3. E. D. Dickmanns, *Dynamic Vision for Perception and Control of Motion*, 1. Ausg. London: Springer-Verlag, 2007.
4. 106th Congress of the United States of America, „National Defense Authorization Act for Fiscal Year 2001“, Okt. 2000. [Online]. Available: <https://www.gpo.gov/fdsys/pkg/PLAW-106publ398/pdf/PLAW-106publ398.pdf>.
5. M. Buehler, K. Iagnemma, und S. Singh, Hrsg., *The DARPA Grand Challenge: The Great Robot Race*, Ser. Springer Tracts in Advanced Robotics, Bd. 36. Springer, 2007.
6. S. Thrun, M. Montemerlo, H. Dahlkamp, D. Stavens, A. Aron, J. Diebel, P. Fong, J. Gale, M. Halpenny, G. Hoffmann, K. Lau, C. Oakley, M. Palatucci, V. Pratt, P. Stang, S. Strohband, C. Dupont, L.-E. Jendrossek, C. Koelen, C. Markey, C. Rummel, J. van Niekerk, E. Jensen, P. Alessandrini, G. Bradski, B. Davies, S. Ettinger, A. Kaehler, A. Nefian, und P. Mahoney, „Stanley: The Robot That Won the DARPA Grand Challenge“, *Journal of Field Robotics*, Bd. 23, Nr. 9, S. 661–692, 2006.
7. M. Buehler, K. Iagnemma, und S. Singh, Hrsg., *The DARPA Urban Challenge: Autonomous Vehicles in City Traffic*, Ser. Springer Tracts in Advanced Robotics, Bd. 56. Springer, 2009.
8. C. Urmson, J. Anhalt, D. Bagnell, C. Baker, R. Bittner, M. N. Clark, J. Dolan, D. Duggins, T. Galatali, C. Geyer, M. Gittleman, S. Harbaugh, M. Hebert, T. M. Howard, S. Kolski, A. Kelly, M. Likhachev, M. McNaughton, N. Miller, K. Peterson, B. Pinnick, R. Rajkumar, P. Rybski, B. Salesky, Y.-W. Seo, S. Singh, J. Snider, A. Stentz, W. Whittaker, Z. Wolkowicki, J. Ziglar, H. Bae, T. Brown, D. Demitrish, B. Litkouhi, J. Nickolaou, V. Sadekar, W. Zhang, J. Struble, M. Taylor, M. Darms, und D. Ferguson, „Autonomous Driving in Urban Environments: Boss and

- the Urban Challenge“, *Journal of Field Robotics*, Bd. 25, Nr. 8, S. 425–466, 2008.
9. Continental, „Alles im Blick – jederzeit und überall: Continental entwickelt das Umfeldmodell der nächsten Generation“, Jan. 2017. [Online]. Available: http://www.continental-corporation.com/www/presseportal_com_de/themen/pressemitteilungen/3_automotive_group/chassis_safety/press_releases/pr_2017_01_04_umfeldmodell_de.html.
 10. D. Yadron und D. Tynan, „Tesla driver dies in first fatal crash while using autopilot mode“, *The Guardian*, Juni 2016. [Online]. Available: <https://www.theguardian.com/technology/2016/jun/30/tesla-autopilot-death-self-driving-car-elon-musk>.
 11. J. Levinson und S. Thrun, „Robust Vehicle Localization in Urban Environments Using Probabilistic Maps“, in *Proc. IEEE Int'l Conf. on Robotics and Automation (ICRA)*, Anchorage, AK, USA, Mai 2010, S. 4372–4378.
 12. T. Dang, M. Lauer, P. Bender, M. Schreiber, J. Ziegler, U. Franke, H. Fritz, T. Strauß, H. Lategahn, C. G. Keller, E. Kaus, C. Rabe, N. Appenrodt, D. Pfeiffer, F. Lindner, F. Stein, F. Erbs, M. Enzweiler, C. Knöppel, J. Hipp, M. Haukeis, M. Trepte, C. Brenk, A. Tamke, M. Ghanaat, M. Braun, A. Joos, H. Mock, M. Hein, D. Petrich, N. Schneider, W. Kronjäger, E. Zeeb, C. Stiller, und R. G. Herrtwich, „Autonomes Fahren auf der historischen Bertha-Benz-Route“, *tm – Technisches Messen*, Bd. 82, Nr. 5, S. 280–297, 2015.
 13. H. Flämig, *Autonome Fahrzeuge und autonomes Fahren im Bereich des Gütertransportes*. Berlin, Heidelberg: Springer, 2015, S. 377–398.
 14. M. Bertozzi, L. Bombini, A. Broggi, M. Buzzoni, E. Cardarelli, S. Cattani, P. Cerri, A. Coati, S. Debattisti, A. Falzoni, R. I. Fedriga, M. Felisa, L. Gatti, A. Giacomazzo, P. Grisleri, M. C. Laghi, L. Mazzei, P. Medici, M. Panciroli, P. P. Porta, P. Zani, und P. Versari, „VIAC: an Out of Ordinary Experiment“, in *Proc. IEEE Intelligent Vehicles Symposium (IV)*, Baden-Baden, Germany, Juni 2011, S. 175–180.
 15. A. Broggi, P. Cerri, M. Felisa, M. C. Laghi, L. Mazzei, und P. P. Porta, „The VisLab Intercontinental Autonomous Challenge: an Extensive Test for a Platoon of Intelligent Vehicles“, *International Journal of Vehicle Autonomous Systems*, Bd. 10, Nr. 3, S. 147–164, 2011.
 16. Deere & Company, „John Deere Precision Ag Technology“, Moline, IL, USA, 2015. [Online]. Available: http://www.deere.com/en_US/docs/html/brochures/publication.html?id=004d03e7.
 17. CLAAS Vertriebsgesellschaft mbH, „CLAAS Lenksysteme“, 2017. [Online]. Available: <http://www.claas.de/blueprint/servlet/blob/1244110/53520d80316902399cf6278ad67309d9/288233dataRaw.pdf>
 18. CLAAS Vertriebsgesellschaft mbH, „CLAAS Crop Sensor ISARIA“, 2015. [Online]. Available: <http://www.claas.de/blueprint/servlet/blob/574408/ec0dbd9ab52cb58f42561fe39942efe3/241391-dataRaw.pdf>.
 19. C. W. Bac, E. J. van Henten, J. Hemming, und Y. Edan, „Harvesting Robots for High-value Crops: State-of-the-art Review and Challenges Ahead“, *Journal of Field Robotics*, Bd. 31, Nr. 6, S. 888–911, 2014.
 20. F. Flemisch, A. Krasni, T. Linder, und P. Boehmsdorff, „Ergonomie für Straßentransport mit Assistenzfunktionen von Robotern: Hochautomatisierte LKW am sicheren Zügel halten“, in *Wehrwissenschaftliche Forschung – Jahresbericht 2014*. Bonn, Germany: Bundesministerium der Verteidigung, Unterabteilung AIN II, Apr. 2015.
 21. F. E. Schneider, D. Wildermuth, und H.-L. Wolf, „ELROB and EURATHLON: Improving search & rescue robotics through real-world robot competitions“, in *10th International Workshop on Robot Motion and Control (RoMoCo)*, Juli 2015, S. 118–123.
 22. S. F. X. Bayerl, T. Luettel, und H.-J. Wuensche, „Following Dirt Roads at Night Time: Sensors and Features for Lane Recognition and Tracking“, in *Proceedings of 7th Workshop On Planning, Perception and Navigation for Intelligent Vehicles (PPNIV), IEEE/RSJ International Conference on Intelligent Robots and Systems*, Hamburg, Germany, Sep. 2015.
 23. H. Jaspers, M. Himmelsbach, und H.-J. Wuensche, „Multi-modal Local Terrain Maps from Vision and LiDAR“, in *Proc. IEEE Intelligent Vehicles Symposium (IV)*, Redondo Beach, CA, USA, Juni 2017.
 24. S. F. X. Bayerl und H.-J. Wuensche, „Detection and Tracking of Rural Crossroads Combining Vision and LiDAR Measurements“, in *Proc. IEEE Intelligent Transportation Systems Conf. (ITSC)*, Qingdao, China, Okt. 2014.
 25. M. Manz, M. Himmelsbach, T. Luettel, und H.-J. Wuensche, „Detection and Tracking of Road Networks in Rural Terrain By Fusing Vision and LiDAR“, in *Proc. IEEE/RSJ Int'l Conf. on Intelligent Robots and Systems (IROS)*, San Francisco, CA, USA, Sep. 2011.
 26. D. Fassbender, A. Mueller, und H.-J. Wuensche, „Trajectory Planning for Car-Like Robots in Unknown, Unstructured Environments“, in *Proc. IEEE/RSJ Int'l Conf. on Intelligent Robots and Systems (IROS)*, Chicago, IL, USA, Sep. 2014.
 27. M. Manz, T. Luettel, F. von Hundelshausen, und H.-J. Wuensche, „Monocular Model-Based 3D Vehicle Tracking for Autonomous Vehicles in Unstructured Environment“, in *Proc. IEEE Int'l Conf. on Robotics and Automation (ICRA)*, Shanghai, China, Mai 2011.
 28. C. Fries, T. Luettel, und H.-J. Wuensche, „Combining Model- and Template-based Vehicle Tracking for Autonomous Convoy Driving“, in *Proc. IEEE Intelligent Vehicles Symposium (IV)*, Gold Coast, Queensland, Australia, Juni 2013.
 29. C. Fries und H.-J. Wuensche, „Real-time Unsupervised Feature Model Generation for a Vehicle Following System“, in *Proc. IEEE Intelligent Transportation Systems Conf. (ITSC)*, Rio de Janeiro, Brazil, Nov. 2016.
 30. M. Himmelsbach, T. Luettel, und H.-J. Wuensche, „Real-time Object Classification in 3D Point Clouds Using Point Feature Histograms“, in *Proc. IEEE/RSJ Int'l Conf. on Intelligent Robots and Systems (IROS)*, St. Louis, MO, USA, Okt. 2009, S. 994–1000.
 31. M. Himmelsbach und H.-J. Wuensche, „Tracking and Classification of Arbitrary Objects with Bottom-Up/Top-Down Detection“, in *Proc. IEEE Intelligent Vehicles Symposium (IV)*, Alcalá de Henares, Spain, Juni 2012, S. 577–582.
 32. M. Himmelsbach, F. von Hundelshausen, und H.-J. Wuensche, „Fast Segmentation of 3D Point Clouds for Ground Vehicles“, in *Proc. IEEE Intelligent Vehicles Symposium (IV)*, San Diego, CA, USA, Juni 2010.
 33. B.-N. Vo und W.-K. Ma, „The Gaussian Mixture Probability Hypothesis Density Filter“, *IEEE Transactions on Signal Processing*, Bd. 54, Nr. 11, S. 4091–4104, 2006.
 34. C. Fries, P. Burger, J. Kallwies, B. Naujoks, T. Luettel, und H.-J. Wuensche, „How MuCAR Won the Convoy Scenario at ELROB

- 2016“, in *Proc. IEEE Intelligent Transportation Systems Conf. (ITSC)*, Yokohama, Japan, 2017, under review.
35. T. Luettel, M. Himmelsbach, und H.-J. Wuensche, „Autonomous Ground Vehicles – Concepts and a Path to the Future“, *Proceedings of the IEEE*, Bd. 100, Special Centennial Issue, S. 1831–1839, Mai 2012.
 36. F. von Hundelshausen, M. Himmelsbach, F. Hecker, A. Mueller, und H.-J. Wuensche, „Driving with Tentacles: Integral Structures of Sensing and Motion“, *Journal of Field Robotics*, Bd. 25, Nr. 9, S. 640–673, 2008.
 37. J. Ziegler, P. Bender, M. Schreiber, H. Lategahn, T. Strauss, C. Stiller, T. Dang, U. Franke, N. Appenrodt, C. G. Keller, E. Kaus, R. G. Herrtwich, C. Rabe, D. Pfeiffer, F. Lindner, F. Stein, F. Erbs, M. Enzweiler, C. Knöppel, J. Hipp, M. Hauéis, M. Treppe, C. Brenk, A. Tamke, M. Ghanaat, M. Braun, A. Joos, H. Fritz, H. Mock, M. Hein, und E. Zeeb, „Making Bertha Drive – An Autonomous Journey on a Historic Route“, *IEEE Intelligent Transportation Systems Magazine*, Bd. 6, Nr. 2, S. 8–20, 2014.
 38. M. Himmelsbach, T. Luettel, F. Hecker, F. von Hundelshausen, und H.-J. Wuensche, „Autonomous Off-Road Navigation for MuCAR-3 – Improving the Tentacles Approach: Integral Structures for Sensing and Motion“, *KI – Künstliche Intelligenz*, Bd. 25, Nr. 2, S. 145–149, 2011, special Issue on Off-Road-Robotics.
 39. J. M. Snider, „Automatic Steering Methods for Autonomous Automobile Path Tracking“, Robotics Institute, Carnegie Mellon University, Pittsburgh, Pennsylvania, Tech. Ber. CMU-RI-TR-09-08, February 2009.
 40. D. Fassbender, B. C. Heinrich, T. Luettel, H.-J. Wuensche, An Optimization Approach to Trajectory Generation for Autonomous Vehicle Following, in *Proc. IEEE/RSJ Int'l Conf. on Intelligent Robots and Systems (IROS)*, Vancouver, BC, Canada, accepted for publication, September 2017.
 41. B. C. Heinrich, T. Luettel, und H.-J. Wuensche, „A New Control Architecture for MuCAR“, in *Proc. IEEE Intelligent Vehicles Symposium (IV)*, Redondo Beach, CA, USA, Juni 2017.
 42. D. Dolgov, S. Thrun, M. Montemerlo, und J. Diebel, „Path Planning for Autonomous Vehicles in Unknown Semi-structured Environments“, *The International Journal of Robotics Research*, Bd. 29, Nr. 5, S. 485–501, 2010.
 43. D. Fassbender, B. C. Heinrich, und H.-J. Wuensche, „Motion Planning for Autonomous Vehicles in Highly Constrained Urban Environments“, in *Proc. IEEE/RSJ Int'l Conf. on Intelligent Robots and Systems (IROS)*, Daejeon, South Korea, Okt. 2016.
 44. D. Fassbender, C. Fries, T. Luettel, und H.-J. Wuensche, „TULF – Automatisiertes Folgen im Konvoi“, in *Wehrwissenschaftliche Forschung – Jahresbericht 2013*. Bonn, Germany: Bundesministerium der Verteidigung, Unterabteilung AIN II, Apr. 2014, S. 52–53.
 45. ELROB.ORG, „M-ELROB 2016 Result Tables“, 2016. [Online]. Available: http://www.elrob.org/files/elrob2016/ELROB_2016_Result_Tables.pdf.
 46. H. Jaspers, D. Fassbender, H.-J. Wuensche, Visual Navigation with Efficient ConvNet Features, in *Proc. IEEE/RSJ Int'l Conf. on Intelligent Robots and Systems (IROS)*, Vancouver, BC, Canada, accepted for publication, September 2017.
 47. D. Fassbender, M. Kusenbach, und H.-J. Wuensche, „Landmark-Based Navigation in Large-Scale Outdoor Environments“, in *Proc. IEEE/RSJ Int'l Conf. on Intelligent Robots and Systems (IROS)*, Hamburg, Germany, Sep. 2015.
 48. M. Link, „Bundesrat stimmt Gesetz für selbstfahrende Autos zu“, Heise Online, 2017. [Online]. Available: <https://heise.de/-3713452>.
 49. Deutscher Bundestag, Ausschuss für Verkehr und digitale Infrastruktur, „Beschlussempfehlung und Bericht: Entwurf eines ... Gesetzes zur Änderung des Straßenverkehrsgesetzes“, Deutscher Bundestag 18. Wahlperiode, Drucksache 18/11776, 2017. [Online]. Available: <http://dip21.bundestag.de/dip21/btd/18/117/1811776.pdf>.
 50. Deutsche Bundesregierung, „Gesetzentwurf der Bundesregierung: Entwurf eines ... Gesetzes zur Änderung des Straßenverkehrsgesetzes“, Deutscher Bundestag 18. Wahlperiode, Drucksache 18/11300, 2017. [Online]. Available: <http://dip21.bundestag.de/dip21/btd/18/113/1811300.pdf>.
 51. J. Markoff, „Military Lags in Push for Robotic Ground Vehicles“, *The New York Times*, Sep. 2013. [Online]. Available: <http://www.nytimes.com/2013/09/24/science/military-lags-in-push-for-robotic-ground-vehicles.html>.

Autoreninformationen



Dipl.-Ing. Thorsten Lüttel

Institut für Technik Autonomer Systeme,
Universität der Bundeswehr München,
Werner-Heisenberg-Weg 39,
85579 Neubiberg
thorsten.luettel@unibw.de

Thorsten Lüttel hat von 2000–2006 Elektrotechnik mit dem Schwerpunkt Mechatronik an der Leibniz Universität Hannover studiert und sich dort vor allem mit zweibeinigen Laufrobotern beschäftigt. Seit 2006 forscht er am Institut für Technik Autonomer Systeme an der Universität der Bundeswehr München im Bereich des autonomen Fahrens. Seine Interessensschwerpunkte liegen im Bereich der Sensordatenfusion und Systemintegration. Des weiteren hat er in den letzten Jahren einige Drittmittelprojekte sowie internationale Wettbewerbsteilnahmen geleitet.



Dipl.-Ing. Felix Ebert

Institut für Technik Autonomer Systeme,
Universität der Bundeswehr München,
Werner-Heisenberg-Weg 39,
85579 Neubiberg
felix.ebert@unibw.de

Felix Ebert studierte von 2007–2014 Elektro- und Informationstechnik mit Schwerpunkt Automatisierungstechnik an der Technischen Universität München. Dort befasste er sich hauptsächlich mit maschinellem Lernen. Seit 2014 forscht er an der Universität der Bundeswehr München im Bereich des autonomen Fahrens, seine Interessensschwerpunkte liegen im Bereich objektrelationale Navigation und Verhalten.



Dipl.-Inform. Dennis Faßbender
Institut für Technik Autonomer Systeme,
Universität der Bundeswehr München,
Werner-Heisenberg-Weg 39,
85579 Neubiberg
dennis.fassbender@unibw.de

Dennis Faßbender studierte von 2006–2012 Informatik an der Universität Koblenz-Landau. Seit August 2012 forscht er als Wissenschaftlicher Mitarbeiter an der Universität der Bundeswehr München. Seine Interessenschwerpunkte liegen im Bereich Trajektorienplanung, Navigation und Verhalten.



Carsten Fries, M.Sc.
Institut für Technik Autonomer Systeme,
Universität der Bundeswehr München,
Werner-Heisenberg-Weg 39,
85579 Neubiberg
carsten.fries@unibw.de

Carsten Fries studierte von 2006–2011 Informatik an der Hochschule für Angewandte Wissenschaften Hamburg. Anschließend forschte er an der Universität der Bundeswehr München im Bereich selbstfahrender Konvoifahrzeuge mit dem Schwerpunkt der modellbasierten Fahrzeugerkennung. Seit 2017 arbeitet er im Bereich Vollautomatisiertes Fahren bei BMW.



Dipl.-Ing. Benjamin C. Heinrich
Institut für Technik Autonomer Systeme,
Universität der Bundeswehr München,
Werner-Heisenberg-Weg 39,
85579 Neubiberg
benjamin.heinrich@unibw.de

Benjamin C. Heinrich studierte an der Universität Stuttgart Technische Kybernetik (Vertiefung Biokybernetik). In seiner Abschlussarbeit an der KTH Stockholm und beim anschließenden Praktikum bei der Ericsson AB, Kista, beschäftigte er sich mit Totzeitkompensation und Optimierung für Mobilfunknetze. Seit 2013 beschäftigt er sich an der Universität der Bundeswehr München mit der Fahrzeugregelung. Seine Forschungsinteressen beinhalten u. a. modellprädiktive Regelung und Totzeitkompensation.



Dipl.-Inf. Hanno Jaspers
Institut für Technik Autonomer Systeme,
Universität der Bundeswehr München,
Werner-Heisenberg-Weg 39,
85579 Neubiberg
hanno.jaspers@unibw.de

Hanno Jaspers hat von 2006–2012 Angewandte Informatik mit dem Schwerpunkt Robotik an der TU Dortmund studiert. Seit 2012 forscht er an der Universität der Bundeswehr München an der visuellen Umfeldwahrnehmung autonomer Fahrzeuge.



Jan Kallwies, M.Sc.
Institut für Technik Autonomer Systeme,
Universität der Bundeswehr München,
Werner-Heisenberg-Weg 39,
85579 Neubiberg
jan.kallwies@unibw.de

Jan Kallwies hat von 2007–2013 Mechatronik an der Friedrich-Alexander-Universität Erlangen-Nürnberg studiert und sich dort vor allem mit praktischen Aufgaben in der Regelungstechnik beschäftigt. Er forscht seit 2013 an der Universität der Bundeswehr München im Bereich des autonomen Fahrens. Seine Interessenschwerpunkte liegen im Bereich der Sensordatenfusion und Stereobildverarbeitung.



Benjamin Naujoks, M.Sc.
Institut für Technik Autonomer Systeme,
Universität der Bundeswehr München,
Werner-Heisenberg-Weg 39,
85579 Neubiberg
benjamin.naujoks@unibw.de

Benjamin Naujoks hat von 2010–2015 Technomathematik an der Technischen Universität Dresden studiert. Seit Ende 2015 arbeitet er als Wissenschaftlicher Mitarbeiter an der Universität der Bundeswehr München. Seine Interessenschwerpunkte liegen im Bereich Detektions- und Tracking-Verfahren in LiDAR-Punktwolken, CUDA-Programmierung sowie Machine-Learning.



Univ.-Prof. Dr.-Ing. Hans-Joachim Wünsche, M.Sc.
Institut für Technik Autonomer Systeme,
Universität der Bundeswehr München,
Werner-Heisenberg-Weg 39,
85579 Neubiberg
jw@unibw.de

Hans-Joachim Wünsche hat an der TU München und der UT Austin/Texas studiert, anschließend hat er 1987 an der Universität der Bundeswehr München zum Thema Bewegungssteuerung durch Rechnersehen promoviert. Nach vielen Jahren in leitenden Positionen in der Industrie kehrte er zu Forschung und Lehre zurück. Seit 2004 ist er Professor und Leiter des Instituts für Technik Autonomer Systeme der Universität der Bundeswehr München. Sein Forschungsschwerpunkt sind autonome Roboter, insbesondere Offroad-Fahrzeuge zum Einsatz in unbekanntem Gelände.